Московский государственный технический университет им. Н.Э. Баумана
Кафедра «Системы обработки информации и управления»

Лабораторная работа
№5 по дисциплине
«Методы машинного обучения»
на тему
«Линейные модели, SVM и деревья решений»

Выполни
л: студент группы ИУ5-
23М
Богомолов Д.Н.

Москва — 2020 г.

Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений.

Подключение библиотек и первичная настройка

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import plotly.express as px
from graphviz import Digraph
```

```
/usr/local/lib/python3.6/dist-packages/statsmodels/tools/_testing.py:19: FutureWarni
  import pandas.util.testing as tm
```

```
!pip install graphviz   #впоследствии не получилось воспользоваться из-за возникнувш
!pip install pydotplus
```

```
Requirement already satisfied: graphviz in /usr/local/lib/python3.6/dist-packages (0
Requirement already satisfied: pydotplus in /usr/local/lib/python3.6/dist-packages (
Requirement already satisfied: pyparsing>=2.0.1 in /usr/local/lib/python3.6/dist-pac
```

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.
```

Задание 1. Выберите набор данных (датасет) для решен задачи классификации или регрессии.

Контекст Этот набор данных создан для прогнозирования поступления выпускников с ин зрения.

Содержание Набор данных содержит несколько параметров, которые считаются важным заявки на магистерские программы. Параметры являются следующими :

- GRE Scores (out of 340)
- TOEFL Scores (out of 120)
- University Rating (out of 5)

- Statement of Purpose and Letter of Recommendation
- Strength (out of 5)
- Undergraduate GPA (out of 10)
- Research Experience (either 0 or 1)
- Chance of Admit (ranging from 0 to 1)
- В датасете отсутствуют пробелы;
- В названиях двух колонок присутствуют пробелы, которые необходимо будет убрать;

```
data1 = pd.read_csv('/content/drive/My Drive/MMO_Datasets/Admission.csv', sep=',')
```

```
strippedCols = dict()
for name in data1.columns:
  strippedCols[name] = name.strip()
data1 = data1.rename(strippedCols, axis='columns', errors='raise')
data1.describe()
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGP
count	500.000000	500.000000	500.000000	500.000000	500.000000	500.00000	500.00000
mean	250.500000	316.472000	107.192000	3.114000	3.374000	3.48400	8.57644
std	144.481833	11.295148	6.081868	1.143512	0.991004	0.92545	0.60481
min	1.000000	290.000000	92.000000	1.000000	1.000000	1.00000	6.80000
25%	125.750000	308.000000	103.000000	2.000000	2.500000	3.00000	8.12750
50%	250.500000	317.000000	107.000000	3.000000	3.500000	3.50000	8.56000
75%	375.250000	325.000000	112.000000	4.000000	4.000000	4.00000	9.04000
max	500.000000	340.000000	120.000000	5.000000	5.000000	5.00000	9.92000

Задание 2. В случае необходимости проведите удаление или заполнение пропусков и код категориальных признаков.

```
data1.isnull().sum()
```

```
Serial No.           0
GRE Score            0
TOEFL Score          0
University Rating    0
SOP                  0
LOR                  0
CGPA                 0
Research             0
Chance of Admit      0
dtype: int64
```

```
import seaborn as sbrn
sbrn.heatmap(data1[data1.columns[1:]].corr(), annot=True, fmt='.2f')
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f709b7997b8>
```

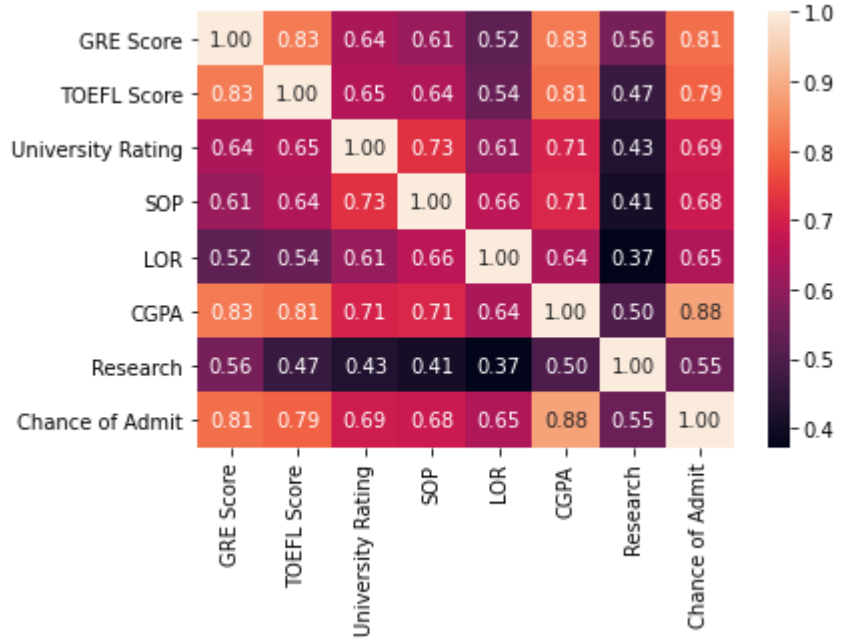

В качестве целевого параметра будем использовать шансы кандидата на поступление - `C`
Самый наибольший коффициент корреляции с переменной `CGPA`

Задание 4. Обучите следующие модели:

- одну из линейных моделей;
- SVM;
- дерево решений.

Линейная модель

Цель построения модели: Определение значения целевой переменной (`Chance of Admit` - поступление кандидата) от значения переменной `CGPA` (оценка за бакалавриат GPA).

Разделение выборки и построение линейной модели

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(data1['CGPA'], \
                                                    data1['Chance of Admit'], \
                                                    test_size=0.3, \
                                                    random_state=42)
```

```
sbrn.scatterplot(x=X_train, y=y_train)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f70964eacf8>
```

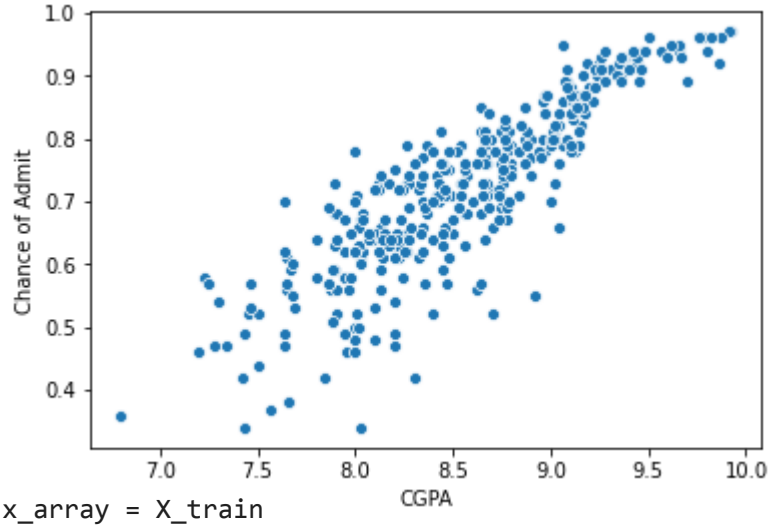


```
x_array = X_train
y_array = y_train
```

Аналитически восстановим зависимость

```
# Аналитическое вычисление коэффициентов регрессии
def analytic_regr_coef(x_array : np.ndarray,
                       y_array : np.ndarray):
    x_mean = np.mean(x_array)
    y_mean = np.mean(y_array)
    var1 = np.sum([(x-x_mean)**2 for x in x_array])
    cov1 = np.sum([(x-x_mean)*(y-x_mean) for x, y in zip(x_array, y_array)])
    b1 = cov1 / var1
    b0 = y_mean - b1*x_mean
    return b0, b1

# Вычисление значений y на основе x для регрессии
def y_regr(x_array : np.ndarray, b0: float, b1: float) -> np.ndarray:
    res = [b1*x+b0 for x in x_array]
    return res
```

```
b0, b1 = analytic_regr_coef(x_array= x_array, y_array= y_array )
print ('Коэффициенты, полученные аналитически:\nb0 = ', b0, '\nb1 = ', b1)
```

```
Коэффициенты, полученные аналитически:
b0 =  -1.0441352652694436
b1 =  0.20617424104989948
```

```
y_array_regr = y_regr( x_array, b0, b1)
plt.plot( x_array, y_array, 'g.')
plt.plot( x_array, y_array_regr, 'b', linewidth=1.2)
plt.show()
```

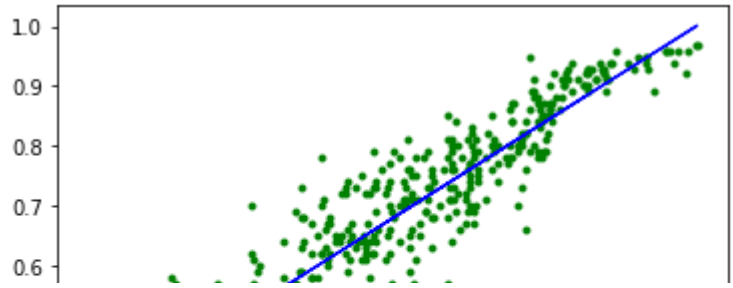

В качестве метода регуляризации линейной регрессии будем использовать L2 регуляриза

$$L = \frac{1}{k} \cdot \sum_{i=1}^{k} (y_i - \sum_{j=0}^{N} b_j \cdot x_{ij})^2 + \alpha \cdot \sum_{j=0}^{N} |b_j| \rightarrow min$$

В качестве гиперпараметра модели будем использовать коэффициент регуляризации.

```
1   from sklearn.linear_model import Ridge
2   from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
3   # Метод создания модели линейной регрессии с применением
4   # гребневой регуляризации на обучающей выборке.
5   # Проверка качества модели на тестовой выборке.
6   def RidgeLinearRegression( alpha,\
7                              X_train,\
8                              X_test, \
9                              y_train, \
10                             y_test):
11    print('Linear Regression. Ridge regulariztaion')
12    print('Alpha=', alpha)
13    print ('Theoretical\tb0=', b0, '\tb1=', b1)
14    reg4 = Ridge( alpha=alpha ).fit(  np.array(X_train).reshape(-1, 1), np.array(y_tra
15    print('Results   \tb0=', reg4.intercept_, ' \tb1=', reg4.coef_)
16    predictResults=reg4.predict(X=np.array(X_test).reshape(-1,1) )
17    print('MSE: \t', mean_squared_error(y_test, predictResults))
18    print('MAE: \t', mean_absolute_error(y_test, predictResults))
19    print('R2: \t', r2_score(y_true=np.array(y_test), y_pred=predictResults ))
20    return reg4
```

Обучение модели с коэффициентом регуляризации равным 10.

```
1   testLR = RidgeLinearRegression(10, X_train, X_test, y_train, y_test)

    Linear Regression. Ridge regulariztaion
    Alpha= 10
    Theoretical     b0= -1.0441352652694436         b1= 0.20617424104989948
    Results         b0= -0.911698261998257          b1= [0.19073211]
    MSE:     0.004389331192428343
    MAE:     0.0465762650745534
    R2:      0.789400341212476
```

Поиск наилучшего гиперпараметра. Применение кросс-валидации и решетчатого поиска

```
1   from sklearn.model_selection import ShuffleSplit
```

```
2   from sklearn.model_selection import GridSearchCV
```

В качестве метода кросс-валидации будем использовать ShuPe Split - случайное "перемеш выборки.

```
1   kf = ShuffleSplit(n_splits=5, test_size=0.3).split(data1['CGPA'], data1['Chance of A
```

Гиперпараметр будет изменяться от 0.1 до 11 с шагом 0.1

```
1   n_range = np.array(np.arange(0.1 ,11. ,0.1 ))
2   tuned_parameters = [{'alpha': n_range}]
3   tuned_parameters
```

```
[{'alpha': array([ 0.1,  0.2,  0.3,  0.4,  0.5,  0.6,  0.7,  0.8,  0.9,  1. ,  1.1,
          1.2,  1.3,  1.4,  1.5,  1.6,  1.7,  1.8,  1.9,  2. ,  2.1,  2.2,
          2.3,  2.4,  2.5,  2.6,  2.7,  2.8,  2.9,  3. ,  3.1,  3.2,  3.3,
          3.4,  3.5,  3.6,  3.7,  3.8,  3.9,  4. ,  4.1,  4.2,  4.3,  4.4,
          4.5,  4.6,  4.7,  4.8,  4.9,  5. ,  5.1,  5.2,  5.3,  5.4,  5.5,
          5.6,  5.7,  5.8,  5.9,  6. ,  6.1,  6.2,  6.3,  6.4,  6.5,  6.6,
          6.7,  6.8,  6.9,  7. ,  7.1,  7.2,  7.3,  7.4,  7.5,  7.6,  7.7,
          7.8,  7.9,  8. ,  8.1,  8.2,  8.3,  8.4,  8.5,  8.6,  8.7,  8.8,
          8.9,  9. ,  9.1,  9.2,  9.3,  9.4,  9.5,  9.6,  9.7,  9.8,  9.9,
         10. , 10.1, 10.2, 10.3, 10.4, 10.5, 10.6, 10.7, 10.8, 10.9])}]
```

В качестве параметра оценки качества модели будем использовать MSE

```
1   clf_gs = GridSearchCV(Ridge(), tuned_parameters, cv=kf, scoring='neg_mean_squared_er
2   clf_gs.fit(np.array(data1['CGPA']).reshape(-1,1), np.array(data1['Chance of Admit'])
```

```
GridSearchCV(cv=<generator object BaseShuffleSplit.split at 0x7f7095fb2f68>,
             error_score=nan,
             estimator=Ridge(alpha=1.0, copy_X=True, fit_intercept=True,
                             max_iter=None, normalize=False, random_state=None,
                             solver='auto', tol=0.001),
             iid='deprecated', n_jobs=None,
             param_grid=[{'alpha': array([ 0.1,  0.2,  0.3,  0.4,  0.5,  0.6,  0.7,
          1.2,  1.3,  1.4,  1.5,  1.6,  1.7,  1.8,  1.9,...
          4.5,  4.6,  4.7,  4.8,  4.9,  5. ,  5.1,  5.2,  5.3,  5.4,  5.5,
          5.6,  5.7,  5.8,  5.9,  6. ,  6.1,  6.2,  6.3,  6.4,  6.5,  6.6,
          6.7,  6.8,  6.9,  7. ,  7.1,  7.2,  7.3,  7.4,  7.5,  7.6,  7.7,
          7.8,  7.9,  8. ,  8.1,  8.2,  8.3,  8.4,  8.5,  8.6,  8.7,  8.8,
          8.9,  9. ,  9.1,  9.2,  9.3,  9.4,  9.5,  9.6,  9.7,  9.8,  9.9,
         10. , 10.1, 10.2, 10.3, 10.4, 10.5, 10.6, 10.7, 10.8, 10.9])}],
             pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
             scoring='neg_mean_squared_error', verbose=0)
```

```
1   clf_gs.best_estimator_
```

```
Ridge(alpha=0.1, copy_X=True, fit_intercept=True, max_iter=None,
      normalize=False, random_state=None, solver='auto', tol=0.001)
```

```
1   clf_gs.best_score_
```

```
-0.004559796848772596
```

```
1  import matplotlib.pyplot as pyplot
2  pyplot.plot(n_range, clf_gs.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x7f70947a9828>]
```

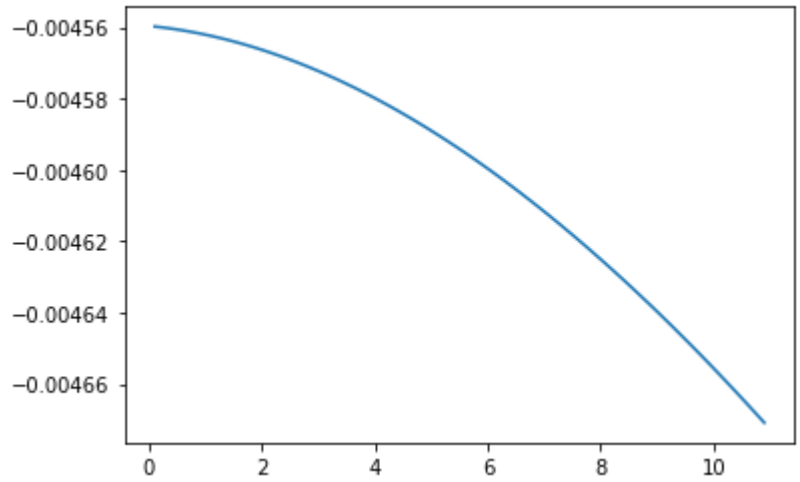

Таким образом, наилучшее качество модели достигается при Гиперпараметре равном 0.1. гиперпараметра способствует увеличению MSE.

Сравнение моделей

```
1  testLR = RidgeLinearRegression(10, X_train, X_test, y_train, y_test)
2  print('\n')
3  optimalLR = RidgeLinearRegression(0.1, X_train, X_test, y_train, y_test)
```

```
Linear Regression. Ridge regulariztaion
Alpha= 10
Theoretical     b0= -1.0441352652694436         b1= 0.20617424104989948
Results         b0= -0.911698261998257          b1= [0.19073211]
MSE:     0.004389331192428343
MAE:     0.0465762650745534
R2:      0.789400341212476


Linear Regression. Ridge regulariztaion
Alpha= 0.1
Theoretical     b0= -1.0441352652694436         b1= 0.20617424104989948
Results         b0= -1.0427048291681977         b1= [0.20600745]
MSE:     0.004304930211816103
MAE:     0.04556950135904033
R2:      0.7934498915742559
```

```
1  regrOld = y_regr( x_array, testLR.intercept_, testLR.coef_)
2  regrNew = y_regr( x_array, optimalLR.intercept_, optimalLR.coef_)
3  plt.plot( x_array, y_array, 'g.')
4  plt.plot( x_array, regrOld, 'b', linewidth=0.8)
5  plt.plot( x_array, regrNew, 'r', linewidth=0.8)
6  plt.show()
7
```

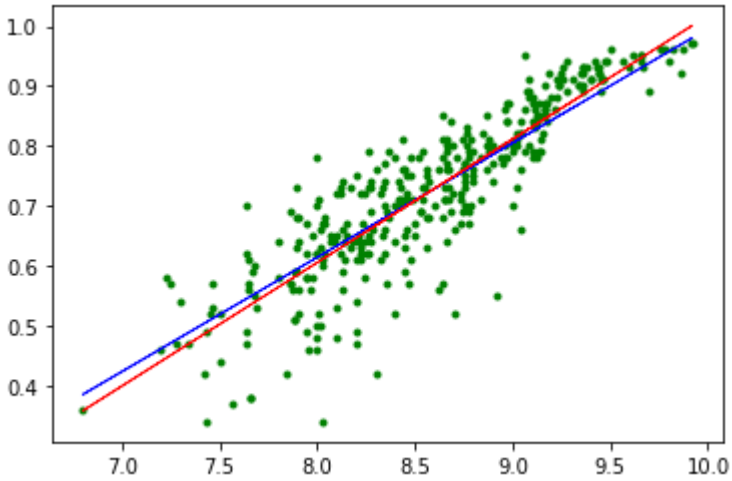

Вывод: Таким образом, с помощью решетчатого поиска и кросс-валидации удалось подоб оптимальный гиперпараметр для построения линейной регрессии с L2 регуляризацией. Н что построенная раннее модель имеет высокую точность, подобранная модель имеет точ (показатель среднего квадрата ошибки хоть и отличается в 6 знаке после запятой, но все Наиболее оптимальный гиперпараметр альфа = 0.1

SVM

Цель построения модели: Предсказание наличия у кандидата исследовательского опыта `Research`) от количества баллов по тестированию GRE (переменная `GRE Score`) и баллов б GPA (переменная `CGPA`).

```
highLevel = data1[data1['Research'] == 1]
lowLevel = data1[data1['Research'] == 0]
```

```
plt.plot( lowLevel['CGPA'], lowLevel['GRE Score'], 'b.')
plt.plot( highLevel['CGPA'], highLevel['GRE Score'], 'r.')
```

```
[<matplotlib.lines.Line2D at 0x7f70946db0b8>]
```

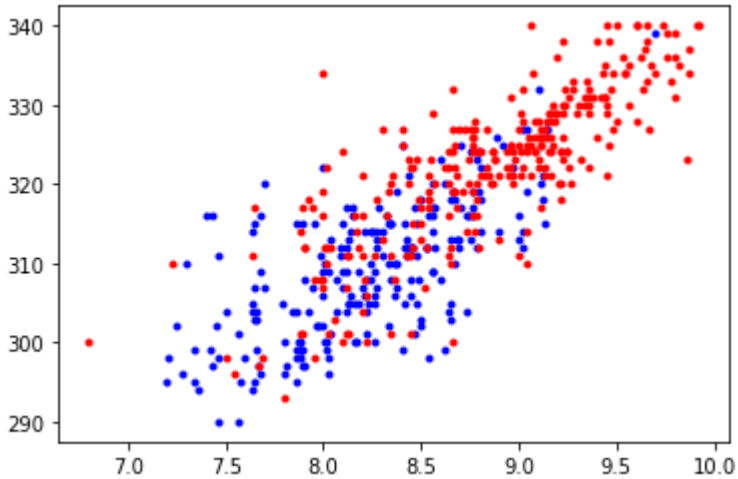

На графике красным отмечены кандидаты с исследовательским опытом работы, тогда ка него.

```
data1[['CGPA', 'GRE Score']].describe()
```

	CGPA	GRE Score
count	500.000000	500.000000
mean	8.576440	316.472000
std	0.604813	11.295148
min	6.800000	290.000000
25%	8.127500	308.000000
50%	8.560000	317.000000
75%	9.040000	325.000000
max	9.920000	340.000000

Однако, перед началом построения модели необходимо выполнить масштабирование, так переменные распределены в различных пределах. Масштабирование существенно влияе моделей SVM.

Масштабирование данных

```
from sklearn.preprocessing import MinMaxScaler
data2 = data1[['CGPA', 'GRE Score', 'Research']]
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data2)
```

```
data3 = pd.DataFrame(data=sc1_data, columns=data2.columns.values)
data3.head()
```

	CGPA	GRE Score	Research
0	0.913462	0.94	1.0
1	0.663462	0.68	1.0
2	0.384615	0.52	1.0
3	0.599359	0.64	1.0
4	0.451923	0.48	0.0

Разделение выборки и построение модели

```
X_train, X_test, y_train, y_test = train_test_split(data3[['CGPA', 'GRE Score']], \
                                                    data3['Research'], \
                                                    test_size=0.3, \
                                                    random_state=42)
```

```
import matplotlib.pyplot as plt
```

```
%matplotlib inline
# Методы визуализации
def make_meshgrid(x, y, h=.02):
    """Create a mesh of points to plot in

    Parameters
    ----------
    x: data to base x-axis meshgrid on
    y: data to base y-axis meshgrid on
    h: stepsize for meshgrid, optional

    Returns
    -------
    xx, yy : ndarray
    """
    x_min, x_max = x.min() - 1, x.max() + 1
    y_min, y_max = y.min() - 1, y.max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                         np.arange(y_min, y_max, h))
    return xx, yy

def plot_contours(ax, clf, xx, yy, **params):
    """Plot the decision boundaries for a classifier.

    Parameters
    ----------
    ax: matplotlib axes object
    clf: a classifier
    xx: meshgrid ndarray
    yy: meshgrid ndarray
    params: dictionary of params to pass to contourf, optional
    """
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)
    #Можно проверить все ли метки классов предсказываются
    #print(np.unique(Z))
    out = ax.contourf(xx, yy, Z, **params)
    return out


def plot_cl(clf):
    title = clf._ repr___
    clf.fit(np.array(X_train), \
            np.array(y_train))
    fig, ax = plt.subplots(figsize=(5,5))
    X0, X1 = X_train.iloc[:,0], X_train.iloc[:, 1]
    xx, yy = make_meshgrid(X0, X1)
    plot_contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
    ax.scatter(X0, X1,c=y_train,  cmap=plt.cm.coolwarm, edgecolors='k')
    ax.set_xlim(xx.min(), xx.max())
    ax.set_ylim(yy.min(), yy.max())
    ax.set_xlabel('CGPA')
    ax.set_ylabel('GRE Score')
    ax.set_xticks(())
    ax.set_yticks(())
```

```
57        ax.set_title(title)
58        plt.show()
```

```
1   X_train
```

	CGPA	GRE Score
5	0.814103	0.80
116	0.583333	0.18
45	0.737179	0.64
16	0.608974	0.54
462	0.365385	0.34
...	...	...
106	0.762821	0.78
270	0.455128	0.32
348	0.144231	0.24
435	0.282051	0.38
102	0.464744	0.48

350 rows × 2 columns

После того, как добавлены методы визуализации, необходимо обучить модель и вычисли оценки ее качества. В качестве гиперпараметра будем использовать коэффициент регуля качестве метрики СКО.

```
1   from sklearn.svm import LinearSVC
2   SvrModel = LinearSVC(C=1, max_iter=1000)
3   plot_cl(SvrModel)
4   SvrModel.fit(X_train, y_train)
5   y_pred = SvrModel.predict( np.array(X_test) )
6   print('\nMSE:',  mean_squared_error(y_test, y_pred))
```

```
<bound method BaseEstimator.__repr__ of LinearSVC(C=1, class_weight=None, dual=True, fit_intercept=T
                                                  intercept_scaling=1, loss='squared_hinge', max_iter=1000,
                                                  multi_class='ovr', penalty='l2', random_state=None, tol=0.0001,
                                                  verbose=0)>
```

Была построена модель с гиперпараметром C=1. СКО = 2,(3). Для того, чтобы улучшить кач
необходимо подобрать гиперпараметр C с импользованием кросс-валидации и решетчато

Поиск наилучшего гиперпараметра. Применение кросс-валидации и решетчатого поиска

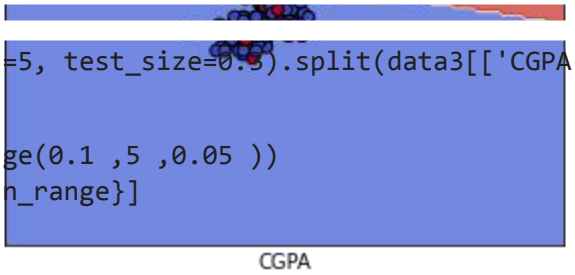


```
1   kf = ShuffleSplit(n_splits=5, test_size=0.5).split(data3[['CGPA', 'GRE Score']], dat
```

```
1   n_range = np.array(np.arange(0.1 ,5 ,0.05 ))
2   tuned_parameters = [{'C': n_range}]
3   tuned_parameters
```

```
[{'C': array([0.1 , 0.15, 0.2 , 0.25, 0.3 , 0.35, 0.4 , 0.45, 0.5 , 0.55, 0.6 ,
         0.65, 0.7 , 0.75, 0.8 , 0.85, 0.9 , 0.95, 1.  , 1.05, 1.1 , 1.15,
         1.2 , 1.25, 1.3 , 1.35, 1.4 , 1.45, 1.5 , 1.55, 1.6 , 1.65, 1.7 ,
         1.75, 1.8 , 1.85, 1.9 , 1.95, 2.  , 2.05, 2.1 , 2.15, 2.2 , 2.25,
         2.3 , 2.35, 2.4 , 2.45, 2.5 , 2.55, 2.6 , 2.65, 2.7 , 2.75, 2.8 ,
         2.85, 2.9 , 2.95, 3.  , 3.05, 3.1 , 3.15, 3.2 , 3.25, 3.3 , 3.35,
         3.4 , 3.45, 3.5 , 3.55, 3.6 , 3.65, 3.7 , 3.75, 3.8 , 3.85, 3.9 ,
         3.95, 4.  , 4.05, 4.1 , 4.15, 4.2 , 4.25, 4.3 , 4.35, 4.4 , 4.45,
         4.5 , 4.55, 4.6 , 4.65, 4.7 , 4.75, 4.8 , 4.85, 4.9 , 4.95])}]
```

```
1   clf_gs = GridSearchCV(LinearSVC(max_iter= 10000), tuned_parameters, cv=kf, scoring='
2   clf_gs.fit(np.array(data3[['CGPA', 'GRE Score']]), np.array(data3['Research']))
```

```
GridSearchCV(cv=<generator object BaseShuffleSplit.split at 0x7f7094733fc0>,
             error_score=nan,
             estimator=LinearSVC(C=1.0, class_weight=None, dual=True,
                                 fit_intercept=True, intercept_scaling=1,
                                 loss='squared_hinge', max_iter=10000,
                                 multi_class='ovr', penalty='l2',
                                 random_state=None, tol=0.0001, verbose=0),
             iid='deprecated', n_jobs=None,
             param_grid=[{'C': array([0.1 , 0.15,...
       1.75, 1.8 , 1.85, 1.9 , 1.95, 2.  , 2.05, 2.1 , 2.15, 2.2 , 2.25,
       2.3 , 2.35, 2.4 , 2.45, 2.5 , 2.55, 2.6 , 2.65, 2.7 , 2.75, 2.8 ,
       2.85, 2.9 , 2.95, 3.  , 3.05, 3.1 , 3.15, 3.2 , 3.25, 3.3 , 3.35,
       3.4 , 3.45, 3.5 , 3.55, 3.6 , 3.65, 3.7 , 3.75, 3.8 , 3.85, 3.9 ,
       3.95, 4.  , 4.05, 4.1 , 4.15, 4.2 , 4.25, 4.3 , 4.35, 4.4 , 4.45,
       4.5 , 4.55, 4.6 , 4.65, 4.7 , 4.75, 4.8 , 4.85, 4.9 , 4.95])}],
             pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
             scoring='neg_mean_squared_error', verbose=0)
```

```
1   print(clf_gs.best_estimator_, '\nMSE:',-clf_gs.best_score_ )
2   print('\n')
3   pyplot.plot(n_range, clf_gs.cv_results_['mean_test_score'])
```

```
LinearSVC(C=1.1500000000000004, class_weight=None, dual=True,
          fit_intercept=True, intercept_scaling=1, loss='squared_hinge',
          max_iter=10000, multi_class='ovr', penalty='l2', random_state=None,
          tol=0.0001, verbose=0)
MSE: 0.2546666666666667


[<matplotlib.lines.Line2D at 0x7f7094405fd0>]
```

По результатам решетчетаго поиска и кросс-валидации, было установлено, что наилучшее модель достигает при C = 2.2. Необхдимо сравнить результаты с моделью, построенной ра

Сравнение моделей

```
1   from sklearn.metrics import accuracy_score, f1_score
2   plot_cl(clf_gs.best_estimator_)
3   y_predBest = clf_gs.best_estimator_.predict( np.array(X_test) )
4   print('\nMSE:',  mean_squared_error(y_test, y_predBest))
5   print('Accuracy:', accuracy_score(y_test, y_predBest))
6   print('F1: ', f1_score(y_test, y_predBest))
7   plot_cl(SvrModel)
8   y_predSvrModel = SvrModel.predict( np.array(X_test) )
9   print('\nMSE:',  mean_squared_error(y_test, y_predSvrModel))
10  print('Accuracy:', accuracy_score(y_test, y_predSvrModel))
11  print('F1: ', f1_score(y_test, y_predSvrModel))
```

<bound method BaseEstimator.__repr__ of LinearSVC(C=1.1500000000000004, class_weight=None, dual=
fit_intercept=True, intercept_scaling=1, loss='squared_hinge',
max_iter=10000, multi_class='ovr', penalty='l2', random_state=None,
tol=0.0001, verbose=0)>

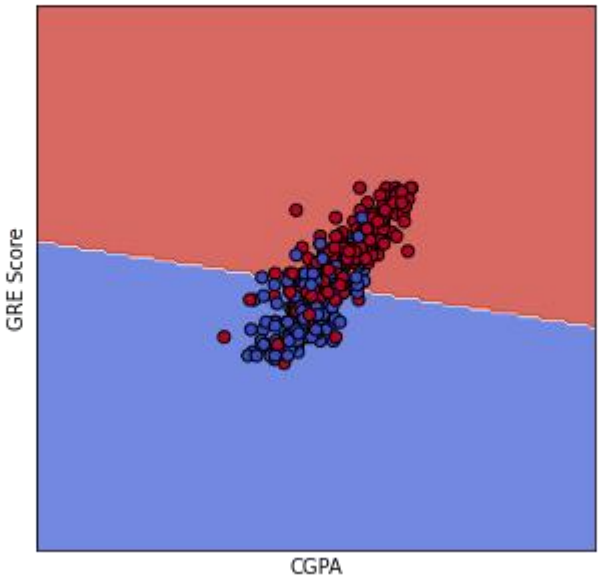


```
MSE: 0.23333333333333334
Accuracy: 0.7666666666666667
F1:  0.7904191616766467
```

<bound method BaseEstimator.__repr__ of LinearSVC(C=1, class_weight=None, dual=True, fit_intercept=T
intercept_scaling=1, loss='squared_hinge', max_iter=1000,
multi_class='ovr', penalty='l2', random_state=None, tol=0.0001,
verbose=0)>

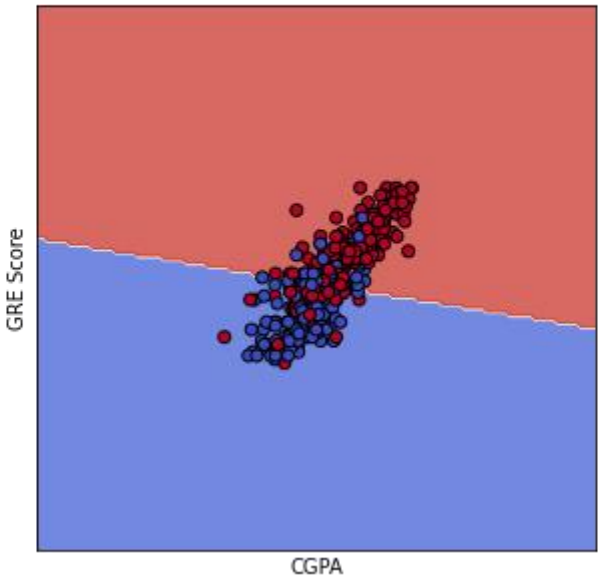


```
MSE: 0.23333333333333334
Accuracy: 0.7666666666666667
F1:  0.7904191616766467
```

Вывод: Метод SVR очень чувствителен к тестовой выборке - даже один случайный выброс повлиять на результаты. На тестовых данных лучший результат показала модель, построе гиперпараметром C=1 (точность незначительно превосходит точность модели, построенн использованием кросс-валидации). Однако, для решения поставленной задачи лучше исп модель, полученную после кросс-валидации, так как она показала лучший результат на пя тестовых выборках (C=0.25).

Дерево решений

Цель построения модели: Классификация шансов на поступление кандидата (малые, сред шансы на поступление) по результатам всех входных данных (баллы бакалавриата, баллы виды тестирования, рейтинг университета и тд.)

Для начала необходимо классифицировать данные из датасета. Каждому кандидату прис зависимости от его шансов на поступление

```
1   data1['Chance of Admit'].describe()
```

```
count    500.00000
mean       0.72174
std        0.14114
min        0.34000
25%        0.63000
50%        0.72000
```

Исходя из описательной статистики следует следующее: наибольший шанс на поступлени наименьший = 0.34. Следующая классификация будет наиболее оптимальной:

- Наименьшие шансы: 0.30 - 0.60
- Средние шансы: 0.60 -0.80
- Наибольшие шансы: 0.80 - 1.00

```
# Метод создания переменной класса
def createClassification( bottomLimit, middleLimit ):
  classes = []
  for val in data1['Chance of Admit'].values:
    if val <= bottomLimit:
      classes.append(1)
    else:
       if val <= middleLimit:
        classes.append(2)
       else:
        classes.append(3)
  return pd.DataFrame(data= np.c_[data1, classes], columns= np.append(data1.columns.
```

```
data4 = createClassification(0.6, 0.8)
data4 = data4.drop(['Chance of Admit'], axis=1)
ax0 = plt.subplot()
class1 = data4[data4['Class']==1].shape[0]
class2 = data4[data4['Class']==2].shape[0]
class3 = data4[data4['Class']==3].shape[0]
ax0.bar( 'class1', class1, label='low chances')
ax0.bar( 'class2', class2, label='middle chances')
ax0.bar( 'class3', class3, label='high chances')
ax0.legend()
plt.show()
```

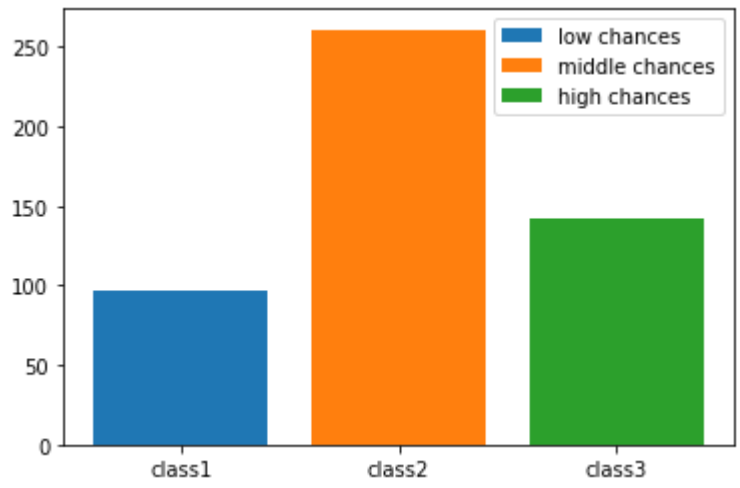


```
data4.head()
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	C
0	1.0	337.0	118.0	4.0	4.5	4.5	9.65	1.0	
1	2.0	324.0	107.0	4.0	4.0	4.5	8.87	1.0	
2	3.0	316.0	104.0	3.0	3.0	3.5	8.00	1.0	
3	4.0	322.0	110.0	3.0	3.5	2.5	8.67	1.0	
4	5.0	314.0	103.0	2.0	2.0	3.0	8.21	0.0	

Таким образом, числовая перменная `Chance of Admit` была заменена категориальной пер
Распределение по классам показало, что у большинства кандидатов имеются средние ша
поступление, меньше кандидатов с выскоими, в меньшестве - кандидаты с низкими шанс

Построение модели

Разделение выборки

```
X_train, X_test, y_train, y_test = train_test_split(data4.loc[:, 'GRE Score':'Resear
                                                    data4['Class'], \
                                                    test_size=0.3, \
                                                    random_state=42)
```

Обучение модели с гиперпараметрами:

- max_depth=5
- max_features=0.2
- min_samples_leaf=0.04

```
from sklearn.tree import DecisionTreeClassifier
testDTModel = DecisionTreeClassifier(random_state=1, max_depth=5, max_features=0.2,
testDTModel.fit(X_train, y_train)
```

```
DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                       max_depth=5, max_features=0.2, max_leaf_nodes=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=0.04, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, presort='deprecated',
                       random_state=1, splitter='best')
```

Оценка качества построенной модели

```
from sklearn.metrics import precision_score, recall_score

testDTModel_predict = testDTModel.predict(np.array(X_test))
print('F1: \t\t', f1_score(y_true= y_test, y_pred= testDTModel_predict, average= 'we
print('Precision: \t',precision_score(y_true= y_test, y_pred= testDTModel_predict, a
print('Recall: \t',recall_score(y_true= y_test, y_pred= testDTModel_predict , averag
print('MSE: \t\t',mean_squared_error(y_true= y_test, y_pred= testDTModel_predict) )
```

```
F1:              0.7589341919969694
Precision:       0.762375478927203
Recall:          0.76
MSE:             0.24
```

Задание 6. Произведите для каждой модели подбор одного гиперпараметра с использованием GridSearchCV и кросс-валид

```
kf = ShuffleSplit(n_splits=5, test_size=0.3).split(data4.loc[:, 'GRE Score':'Researc
```

```
params = {
    'max_depth': [3, 4, 5, 6],
    'min_samples_leaf': [0.04, 0.06, 0.08],
    'max_features': [0.2, 0.4, 0.6, 0.8]
}
```

```
grid_1 = GridSearchCV(estimator=DecisionTreeClassifier(random_state=1),
                      param_grid= params, scoring='neg_mean_squared_error', cv=kf)
grid_1.fit(data4.loc[:, 'GRE Score':'Research'], data4['Class'])
```

```
GridSearchCV(cv=<generator object BaseShuffleSplit.split at 0x7f7092fb7938>,
             error_score=nan,
             estimator=DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None,
                                              criterion='gini', max_depth=None,
                                              max_features=None,
                                              max_leaf_nodes=None,
                                              min_impurity_decrease=0.0,
                                              min_impurity_split=None,
                                              min_samples_leaf=1,
                                              min_samples_split=2,
                                              min_weight_fraction_leaf=0.0,
                                              presort='deprecated',
                                              random_state=1, splitter='best'),
             iid='deprecated', n_jobs=None,
             param_grid={'max_depth': [3, 4, 5, 6],
                         'max_features': [0.2, 0.4, 0.6, 0.8],
                         'min_samples_leaf': [0.04, 0.06, 0.08]},
             pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
             scoring='neg_mean_squared_error', verbose=0)
```

```
grid_1.best_estimator_, -grid_1.best_score_
```

```
(DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                        max_depth=4, max_features=0.6, max_leaf_nodes=None,
                        min_impurity_decrease=0.0, min_impurity_split=None,
                        min_samples_leaf=0.04, min_samples_split=2,
                        min_weight_fraction_leaf=0.0, presort='deprecated',
                        random_state=1, splitter='best'), 0.1853333333333333)
```

В результате кросс-валидации и решетчатого поиска была найдена наилучшая модель со гиперпараметрами:

- max_depth=3
- max_features=0.8
- min_samples_leaf=0.08

Задание 7. Сравните качество полученных моделей с качество полученных в пункте 4.

Доп. задание. Рассмотрим распределение важности среди переменных в полученной мод

```
from operator import itemgetter

def draw_feature_importances(tree_model, X_dataset, figsize=(15,7)):
    """
    Вывод важности признаков в виде графика
    """
    # Сортировка значений важности признаков по убыванию
    list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances
    sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
    # Названия признаков
    labels = [x for x,_ in sorted_list]
    # Важности признаков
    data = [x for _,x in sorted_list]
    # Вывод графика
    fig, ax = plt.subplots(figsize=figsize)
    ind = np.arange(len(labels))
    plt.bar(ind, data)
    plt.xticks(ind, labels, rotation='vertical')
    # Вывод значений
    for a,b in zip(ind, data):
        plt.text(a-0.05, b+0.01, str(round(b,3)))
    plt.show()
    return labels, data
```

```
_1,_2 = draw_feature_importances(grid_1.best_estimator_, data4.loc[:, 'GRE Score':'R
```

А также для модели, полученой раннее

```
1   _1,_2 = draw_feature_importances(testDTModel, data4.loc[:, 'GRE Score':'Research'])
```

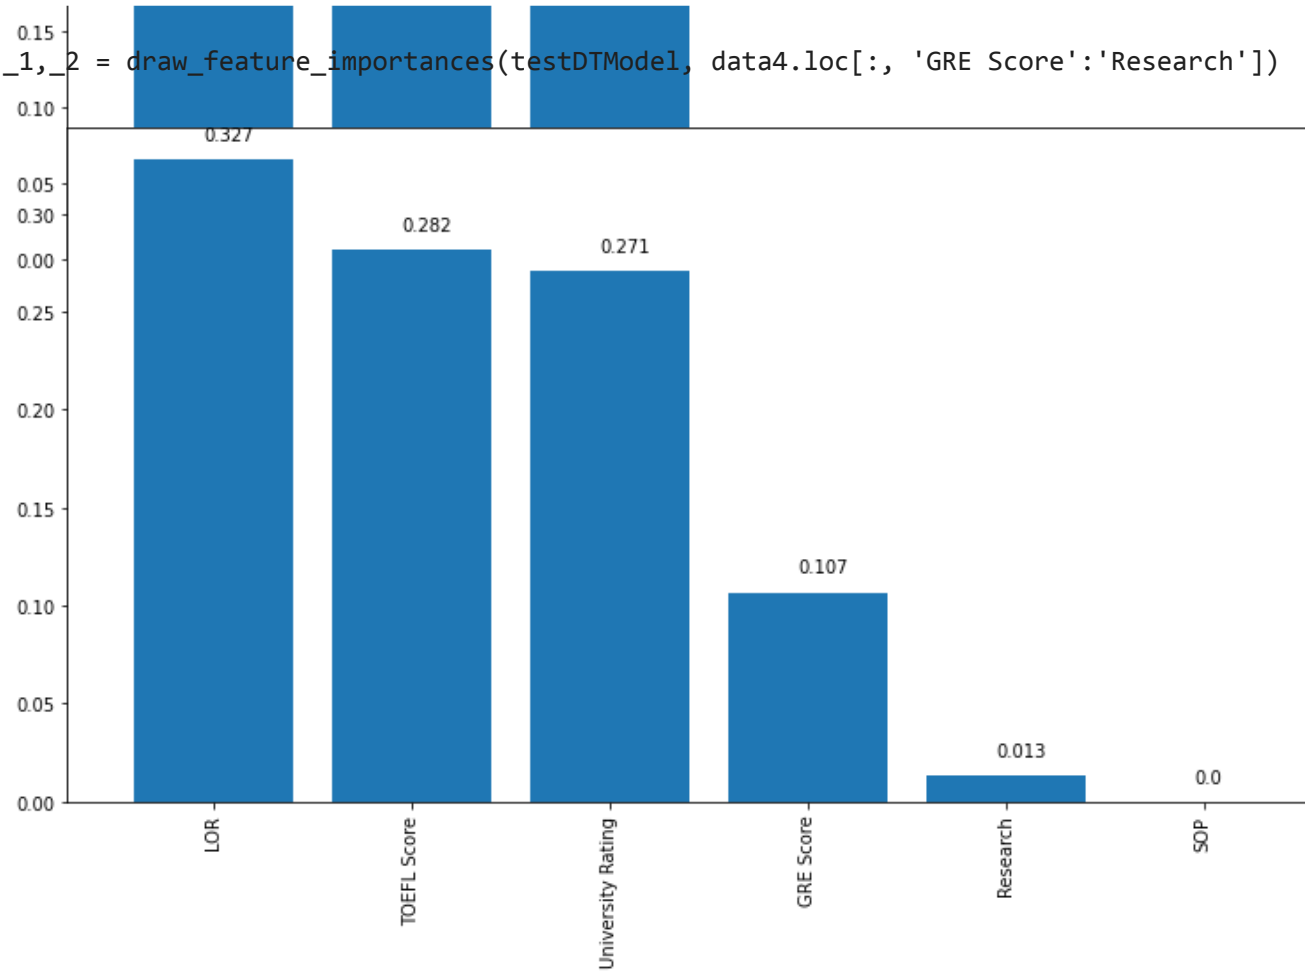

Для полноты сравнения, рассмотрим метрики качества для двух моделей

```
1   print('Test Descision Tree Model')
2   print('F1: \t\t', f1_score(y_true= y_test, y_pred= testDTModel_predict, average= 'we
3   print('Precision: \t',precision_score(y_true= y_test, y_pred= testDTModel_predict, a
4   print('Recall: \t',recall_score(y_true= y_test, y_pred= testDTModel_predict , averag
5   print('MSE: \t\t',mean_squared_error(y_true= y_test, y_pred= testDTModel_predict) )
6   bestDTModel_predict = grid_1.best_estimator_.predict(np.array(X_test))
7   print('\nBest Descision Tree Model')
8   print('F1: \t\t', f1_score(y_true= y_test, y_pred= bestDTModel_predict, average= 'we
9   print('Precision: \t',precision_score(y_true= y_test, y_pred= bestDTModel_predict, a
10  print('Recall: \t',recall_score(y_true= y_test, y_pred= bestDTModel_predict , averag
11  print('MSE: \t\t',mean_squared_error(y_true= y_test, y_pred= bestDTModel_predict) )
```

```
Test Descision Tree Model
F1:              0.7589341919969694
Precision:       0.762375478927203
Recall:          0.76
MSE:             0.24

Best Descision Tree Model
F1:              0.8245397093748742
Precision:       0.832561403508772
Recall:          0.8333333333333334
MSE:             0.16666666666666666
```